

От primal ERM к dual Frank--Wolfe

Явный вывод обновлений для dual variables и исходного параметра w

Техническая записка

16 июля 2026

1. Исходная задача

Начнем с

$$\min_{w \in \mathbb{R}^d} P(w) := R(w) + \frac{1}{n} \sum_{i=1}^n f_i(K_i w). \quad (1)$$

Здесь K_i может быть identity; он оставлен, чтобы одна формула покрывала linear prediction, последнюю голову сети и structured score. Предполагаем, что R и f_i --- proper closed convex functions и выполнено strong duality. Для произвольной nonconvex end-to-end сети это не автоматический факт: дальнейшие формулы точны, если loss имеет convex или точное saddle/max представление.

По определению Fenchel conjugate

$$f_i(z) = \max_{\alpha_i} \{ \langle \alpha_i, z \rangle - f_i^*(\alpha_i) \}.$$

Подставляем это в (1):

$$P^* = \min_w \max_{\alpha_1, \dots, \alpha_n} \left[R(w) + \frac{1}{n} \sum_i (\langle \alpha_i, K_i w \rangle - f_i^*(\alpha_i)) \right]. \quad (2)$$

Введем агрегированную dual-переменную в пространстве параметров:

$$v(\alpha) := -\frac{1}{n} \sum_{i=1}^n K_i^* \alpha_i. \quad (3)$$

После перестановки min и max минимизация по w равна

$$\min_w \{ R(w) - \langle v(\alpha), w \rangle \} = -R^*(v(\alpha)).$$

Поэтому dual problem имеет вид

$$\max_{\alpha_i \in \text{dom } f_i^*} D(\alpha) := -R^*(v(\alpha)) - \frac{1}{n} \sum_i f_i^*(\alpha_i). \quad (4)$$

Для Frank--Wolfe удобнее минимизировать минус dual objective:

$$\min_{\alpha \in \mathcal{A}} F(\alpha) := R^*(v(\alpha)) + \frac{1}{n} \sum_i f_i^*(\alpha_i), \quad \mathcal{A} = \prod_{i=1}^n \text{dom } f_i^*. \quad (5)$$

2. Как из dual variables получается исходный w

Минимизатор лагранжиана по w удовлетворяет

$$0 \in \partial R(w) - v(\alpha).$$

Если R строго выпукла, recovery map однозначна:

$$w(\alpha) = \nabla R^*(v(\alpha)). \quad (6)$$

Это центральная формула: мы оптимизируем α , а параметр исходной модели каждый раз получаем через gradient conjugate регуляризатора.

Если f_i^* дифференцируема, block-gradient dual objective равен

$$\nabla_i F(\alpha) = \frac{1}{n} [\nabla f_i^*(\alpha_i) - K_i w(\alpha)]. \quad (7)$$

Действительно, $\partial v / \partial \alpha_i = -K_i^* / n$, а $\nabla R^*(v) = w$.

3. Frank--Wolfe update в dual-пространстве

Пусть $\mathcal{A}$ компактна и F гладкая. Полный linear minimization oracle:

$$s^t \in \arg \min_{s \in \mathcal{A}} \langle s, \nabla F(\alpha^t) \rangle. \quad (8)$$

Так как $\mathcal{A} = \mathcal{A}_1 \times \dots \times \mathcal{A}_n$, он распадается:

$$s_i^t \in \arg \min_{s_i \in \mathcal{A}_i} \langle s_i, \nabla f_i^*(\alpha_i^t) - K_i w^t \rangle, \quad i = 1, \dots, n, \quad (9)$$

где общий множитель $1/n$ отброшен. Dual Frank--Wolfe update:

$$\alpha^{t+1} = (1 - \gamma_t) \alpha^t + \gamma_t s^t. \quad (10)$$

Теперь явно переведем этот update обратно в primal-параметр. Из линейности $v(\alpha)$:

$$v^{t+1} = (1 - \gamma_t) v^t + \gamma_t v(s^t), \quad (11)$$

$$w^{t+1} = \nabla R^*((1 - \gamma_t) v^t + \gamma_t v(s^t)). \quad (12)$$

В общем случае это *не* convex combination между w^t и $w(s^t)$, потому что map ∇R^* может быть нелинейной. Такое простое усреднение возникает для quadratic regularizer.

3.1. Block-coordinate update

Если обновляем только блоки $B_t \subseteq \{1, \dots, n\}$, то

$$\alpha_i^{t+1} = (1 - \gamma_{t,i}) \alpha_i^t + \gamma_{t,i} s_i^t, \quad i \in B_t, \quad (13)$$

$$\alpha_i^{t+1} = \alpha_i^t, \quad i \notin B_t. \quad (14)$$

Агрегат и исходный параметр обновляются как

$$v^{t+1} = v^t - \frac{1}{n} \sum_{i \in B_t} K_i^* (\alpha_i^{t+1} - \alpha_i^t), \quad (15)$$

$$w^{t+1} = \nabla R^*(v^{t+1}). \quad (16)$$

То есть для BCFW не нужно пересчитывать сумму по всему датасету: достаточно изменить вклад выбранных dual blocks и применить recovery map.

4. Чистая max/hinge-форма

Для Frank--Wolfe особенно удобен случай

$$f_i(w) = \max_{a_i \in \mathcal{A}_i} \langle a_i, b_i - M_i w \rangle, \quad (17)$$

где $\mathcal{A}_i$ --- компактное множество альтернатив. Тогда

$$q(a) = \frac{1}{n} \sum_i M_i^* a_i, \quad (18)$$

$$F(a) = R^*(q(a)) - \frac{1}{n} \sum_i \langle a_i, b_i \rangle, \quad (19)$$

$$\boxed{w(a) = \nabla R^*(q(a)),} \quad (20)$$

$$\nabla_i F(a) = \frac{1}{n} (M_i w(a) - b_i). \quad (21)$$

Здесь LMO совсем простой:

$$\boxed{s_i^t \in \arg \min_{s_i \in \mathcal{A}_i} \langle s_i, M_i w^t - b_i \rangle = \arg \max_{s_i \in \mathcal{A}_i} \langle s_i, b_i - M_i w^t \rangle.} \quad (22)$$

Это и есть выбор наиболее нарушенной alternative/label/constraint при текущей модели. После него

$$a_i^{t+1} = (1 - \gamma_t) a_i^t + \gamma_t s_i^t, \quad (23)$$

$$q^{t+1} = q^t + \frac{\gamma_t}{n} \sum_{i \in B_t} M_i^* (s_i^t - a_i^t), \quad (24)$$

$$\boxed{w^{t+1} = \nabla R^*(q^{t+1}).} \quad (25)$$

5. Подстановка конкретных регуляризаторов

Во всех формулах ниже q означает агрегат из max-form. Для общей Fenchel-формы нужно просто заменить q на v .

5.1. Обычный quadratic regularizer

Пусть

$$R(w) = \frac{\lambda}{2} \|w\|_2^2, \quad R^*(q) = \frac{1}{2\lambda} \|q\|_2^2.$$

Тогда

$$\boxed{w = \frac{q}{\lambda}.} \quad (26)$$

Для full FW:

$$\boxed{w^{t+1} = (1 - \gamma_t) w^t + \gamma_t \frac{q(s^t)}{\lambda}.} \quad (27)$$

Для block update:

$$\boxed{w^{t+1} = w^t + \frac{1}{\lambda n} \sum_{i \in B_t} \gamma_{t,i} M_i^* (s_i^t - a_i^t).} \quad (28)$$

5.2. Weighted quadratic regularizer

Для $H \succ 0$:

$$R(w) = \frac{\lambda}{2} w^\top H w, \quad R^*(q) = \frac{1}{2\lambda} q^\top H^{-1} q, \quad \boxed{w = \frac{1}{\lambda} H^{-1} q.}$$

Следовательно,

$$\boxed{w^{t+1} = w^t + \frac{1}{\lambda n} H^{-1} \sum_{i \in B_t} \gamma_{t,i} M_i^*(s_i^t - a_i^t).} \quad (29)$$

5.3. p -power regularizer

Пусть $p > 1$, $p^{-1} + r^{-1} = 1$, и

$$R(w) = \frac{\lambda}{p} \|w\|_p^p.$$

Тогда

$$R^*(q) = \frac{\lambda^{1-r}}{r} \|q\|_r^r, \quad \boxed{w_j = \lambda^{1-r} \text{sign}(q_j) |q_j|^{r-1}.}$$

После FW update сначала обновляется q^{t+1} по (24), затем эта формула применяется по координатам. При $p \neq 2$ update по w нелинеен.

5.4. Elastic net

Пусть

$$R(w) = \lambda_1 \|w\|_1 + \frac{\lambda_2}{2} \|w\|_2^2, \quad \lambda_2 > 0.$$

Тогда

$$R^*(q) = \frac{1}{2\lambda_2} \|\text{soft}(q, \lambda_1)\|_2^2, \quad (30)$$

$$\boxed{w = \frac{1}{\lambda_2} \text{soft}(q, \lambda_1),} \quad (31)$$

где $\text{soft}(q, \tau)_j = \text{sign}(q_j)(|q_j| - \tau)_+$. Поэтому BCFW обновляет q линейно, а затем применяет soft-thresholding.

5.5. Entropy regularizer на simplex

Если $w \in \Delta_d$ и

$$R(w) = \lambda \sum_j w_j \log w_j + I_{\Delta_d}(w),$$

то

$$R^*(q) = \lambda \log \sum_j \exp(q_j / \lambda), \quad (32)$$

$$\boxed{w = \text{softmax}(q/\lambda).} \quad (33)$$

Здесь FW update dual aggregate q превращается в multiplicative/softmax-like изменение исходного w , а не в линейное усреднение.

5.6. Чистый ℓ_1 -regularizer

Для $R(w) = \lambda \|w\|_1$:

$$R^*(q) = I_{\{\|q\|_\infty \leq \lambda\}}(q).$$

Conjugate негладкая, а $w = \nabla R^*(q)$ не определено однозначно. Поэтому чистый ℓ_1 не дает описанный выше гладкий dual FW без дополнительного smoothing или небольшой quadratic component. Elastic net устраняет эту проблему.

6. Итоговая схема

Для max/hinge DL subproblem вся итерация сводится к четырем строкам:

$$\begin{aligned} w^t &= \nabla R^*(q^t), \\ s_i^t &\in \arg \max_{s_i \in \mathcal{A}_i} \langle s_i, b_i - M_i w^t \rangle, \quad i \in B_t, \\ q^{t+1} &= q^t + \frac{1}{n} \sum_{i \in B_t} \gamma_{t,i} M_i^* (s_i^t - a_i^t), \\ a_i^{t+1} &= (1 - \gamma_{t,i}) a_i^t + \gamma_{t,i} s_i^t, \quad w^{t+1} = \nabla R^*(q^{t+1}). \end{aligned}$$

Регуляризатор полностью определяет отображение $q \mapsto w$. Quadratic дает линейный update, p -regularizer --- степенной, elastic net --- soft-thresholding, entropy --- softmax.