

Дуализация как механизм обнаружения блочной структуры

От ERM к Frank--Wolfe, block-coordinate Frank--Wolfe и децентрализованным вариантам

Исследовательская заметка проекта Decentralized Block-Coordinate Frank--Wolfe

16 июля 2026

Аннотация

Рассматривается общий механизм, при котором регуляризованная задача эмпирического риска после Fenchel--Lagrange dualization приобретает декартову структуру по объектам данных. Для выпуклой задачи $\min_w R(w) + n^{-1} \sum_i f_i(K_i w)$ dual variables естественно группируются как $\alpha = (\alpha_1, \dots, \alpha_n)$, а допустимая область равна произведению локальных областей сопряженных функций, если исходные summands и ограничения не связывают разные примеры. Для max-form losses и сильно выпуклого R dual становится гладкой выпуклой минимизацией на product set; primal-параметр восстанавливается как $w(\alpha) = \nabla R^*(q(\alpha))$, а Frank--Wolfe gap совпадает с primal--dual gap. Полный linear minimization oracle раскладывается по блокам, но вызывает все локальные inference oracles. Block-coordinate Frank--Wolfe сохраняет ту же глобальную допустимую область, вызывая oracle только для выбранных блоков. Мы формализуем условия этого перехода, отделяем метод от stochastic gradient, описываем decentralized extension и протокол честного сравнения. Существенная граница применимости: результат не переносится автоматически на произвольную end-to-end deep learning задачу, поскольку nonconvex parametrization разрушает выпуклую dual equivalence; корректные применения включают выпуклые головы, structured layers, convex surrogates и отдельные constrained subproblems.

1. Мотивация и основной тезис

Стандартная запись обучения

$$\min_w \frac{1}{n} \sum_{i=1}^n f_i(w) + R(w) \quad (1)$$

скрывает важную структуру: все объекты используют один и тот же параметр w , поэтому primal выглядит полностью связанным. Но связь находится в параметре, а *негладкость или ограничения* часто локальны: один hinge, один epigraph, одна structured alternative family или один demand относятся только к одному i . После dualization общая переменная w устраняется, а локальные ограничения получают локальные multipliers α_i . В результате связь переносится из feasible set в гладкую целевую функцию через агрегат $\sum_i K_i^* \alpha_i$, тогда как feasible set распадается:

$$\alpha \in \mathcal{A} = \mathcal{A}_1 \times \dots \times \mathcal{A}_n.$$

Это и есть основной механизм. Дуализация здесь полезна не только как источник lower bound: она меняет геометрию вычисления. Полный FW oracle на product set равен набору независимых локальных oracle calls, а BCFW может выполнить только небольшую их часть.

локальная сумма/ограничения в primal $\implies$ локальные dual variables $\implies$
product feasible set $\implies$ block-separable LMO.

2. Общий Fenchel dual для регуляризованного ERM

Пусть $w \in \mathbb{R}^d$, $K_i : \mathbb{R}^d \rightarrow \mathbb{R}^{m_i}$ --- линейные отображения, а R и f_i --- proper closed convex functions. Рассмотрим

$$P^* = \min_{w \in \mathbb{R}^d} \left\{ P(w) := R(w) + \frac{1}{n} \sum_{i=1}^n f_i(K_i w) \right\}. \quad (2)$$

Используя $f_i(z) = \sup_{\alpha_i} \{ \langle \alpha_i, z \rangle - f_i^*(\alpha_i) \}$, получаем седловую форму

$$\min_w \sup_{\alpha_1, \dots, \alpha_n} R(w) + \frac{1}{n} \sum_i (\langle \alpha_i, K_i w \rangle - f_i^*(\alpha_i)).$$

При стандартной constraint qualification (например, существует $w_0 \in \text{dom } R$, для которого все $K_i w_0$ лежат в относительной внутренней соответствующих $\text{dom } f_i$) $\min$ и $\sup$ можно переставить. Минимизация по w дает Fenchel dual [2, 5]

$$D^* = \max_{\alpha_i \in \text{dom } f_i^*} \left\{ -R^* \left(-\frac{1}{n} \sum_i K_i^* \alpha_i \right) - \frac{1}{n} \sum_i f_i^*(\alpha_i) \right\}. \quad (3)$$

Теорема 1 (Когда возникает product-структура). Для задачи (2) допустимая dual-область является $\mathcal{A} = \prod_i \text{dom } f_i^*$, если каждый summand имеет собственную сопряженную переменную и в primal нет дополнительных ограничений, связывающих значения разных i . Связь между блоками сохраняется только в objective через $\sum_i K_i^* \alpha_i$. Если же primal содержит coupled constraint, например $\sum_i C_i z_i = c$, его multiplier или соответствующее dual-ограничение связывает блоки и чистая product-структура, вообще говоря, исчезает.

Доказательство. Область супремума в Fenchel representation каждого f_i равна $\text{dom } f_i^*$ и выбирается независимо от остальных. После устранения w никакого нового feasibility constraint не возникает: сумма $K_i^* \alpha_i$ входит аргументом в R^* . Дополнительное coupled constraint добавило бы в лагранжиан общий multiplier или indicator of a coupled set, что нарушило бы независимость областей. $\square$

Теорема объясняет происхождение блоков, но еще не гарантирует применимость *обычного* FW. Для классического анализа нужны компактная выпуклая $\mathcal{A}$ и гладкая выпуклая минимизируемая функция. В (3) слагаемые f_i^* могут быть нелинейными или негладкими. Поэтому наиболее чистая FW-форма возникает для max/hinge losses, чьи conjugates состоят из indicator of a compact set и линейного члена. В более общем случае применим generalized/composite conditional gradient, либо epigraph lifting, но не всегда стандартный FW [1].

3. Max-form: каноническая задача для Frank--Wolfe

Пусть локальный loss имеет вариационное представление

$$H_i(w) = \max_{a_i \in \mathcal{A}_i} \langle a_i, b_i - M_i w \rangle, \quad (4)$$

где $\mathcal{A}_i \subset \mathbb{R}^{m_i}$ --- непустое компактное выпуклое множество. Оно может быть симплексом distributions over labels, convex hull альтернатив, capacity polytope или локальным множеством multipliers. Primal равен

$$\min_w P(w) := R(w) + \frac{1}{n} \sum_i H_i(w). \quad (5)$$

Обозначим

$$q(a) = \frac{1}{n} \sum_i M_i^* a_i, \quad \mathcal{A} = \prod_i \mathcal{A}_i.$$

Лагранжиан-седловая функция и concave dual имеют вид

$$L(w, a) = R(w) + \frac{1}{n} \sum_i \langle a_i, b_i - M_i w \rangle, \quad (6)$$

$$D(a) = \frac{1}{n} \sum_i \langle a_i, b_i \rangle - R^*(q(a)), \quad \max_{a \in \mathcal{A}} D(a). \quad (7)$$

Эквивалентная FW-задача --- минимизация

$$F(a) := -D(a) = R^*(q(a)) - \frac{1}{n} \sum_i \langle a_i, b_i \rangle \quad \text{на } \mathcal{A}. \quad (8)$$

3.1. Primal recovery и гладкость dual

Если R строго выпукла и минимум по w единственен, primal recovery map равна

$$w(a) = \arg \min_w L(w, a) = \nabla R^*(q(a)). \quad (9)$$

Если R μ -сильно выпукла, то R^* дифференцируема и ∇R^* имеет Lipschitz constant $1/\mu$. Следовательно, F гладкая, а ее block-gradient равен

$$\nabla_i F(a) = \frac{1}{n} (M_i w(a) - b_i). \quad (10)$$

Для $R(w) = \frac{\lambda}{2} \|w\|_2^2$:

$$w(a) = \frac{q(a)}{\lambda}, \quad F(a) = \frac{\|q(a)\|_2^2}{2\lambda} - \frac{1}{n} \sum_i \langle a_i, b_i \rangle. \quad (11)$$

Утверждение 1 (FW gap равен primal--dual gap). Пусть выполнены условия max-form выше и $w(a)$ задано (9). Тогда

$$g_{\text{FW}}(a) := \max_{s \in \mathcal{A}} \langle a - s, \nabla F(a) \rangle \quad (12)$$

$$= P(w(a)) - D(a) \quad (13)$$

$$= \frac{1}{n} \sum_i [H_i(w(a)) - \langle a_i, b_i - M_i w(a) \rangle] \geq 0. \quad (14)$$

Доказательство. По (10) максимизация FW gap распадается по блокам. Для каждого i , $\max_{s_i \in \mathcal{A}_i} \langle a_i - s_i, M_i w - b_i \rangle / n$ равна $n^{-1} [H_i(w) - \langle a_i, b_i - M_i w \rangle]$. Сумма этих выражений совпадает с $P(w) - D(a)$, поскольку равенство Fenchel--Young для $w = \nabla R^*(q)$ дает $R(w) + R^*(q) = \langle q, w \rangle$. $\square$

Отсюда следует точный ответ на вопрос, почему улучшение dual улучшает primal solution. Dual objective дает возрастающий lower bound $D(a) \leq P^*$, recovery map строит конкретный primal iterate, а (14) сертифицирует его качество:

$$0 \leq P(w(a)) - P^* \leq P(w(a)) - D(a) = g_{\text{FW}}(a).$$

При μ -сильно выпуклом P дополнительно $\|w(a) - w^*\|^2 \leq 2g_{\text{FW}}(a)/\mu$.

4. Почему full LMO дорогой

Обычный FW строит [3]

$$s \in \arg \min_{u \in \mathcal{A}} \langle u, \nabla F(a) \rangle. \quad (15)$$

Из product-структуры следует

$$s_i \in \arg \min_{u_i \in \mathcal{A}_i} \langle u_i, M_i w(a) - b_i \rangle, \quad i = 1, \dots, n. \quad (16)$$

Алгебраически это идеальная декомпозиция. Вычислительно она означает n oracle calls за одну full iteration. В Structural SVM каждый call --- loss-augmented inference over a combinatorial output space. В routing/transport это поиск по всем demands или columns. Если один oracle стоит C_i , то full LMO стоит $\sum_i C_i$, даже если все вызовы могут быть распараллелены. Parallelism уменьшает latency только при достаточном числе вычислителей и не устраняет total work.

Полный gap также требует всех block oracles. Поэтому при редких block updates полезно различать: (i) дешевую update-стоимость; (ii) периодическую дорогую full-gap диагностику; (iii) unbiased или upper-bound gap estimators, если они допустимы для конкретного анализа.

5. Block-coordinate Frank--Wolfe

На итерации t выбирается $B_t \subseteq \{1, \dots, n\}$. Для $i \in B_t$ вычисляется (16), после чего

$$a_i^{t+1} = (1 - \gamma_{t,i})a_i^t + \gamma_{t,i}s_i^t, \quad i \in B_t, \quad (17)$$

а остальные блоки не меняются. Поскольку a_i^t и s_i^t принадлежат $\mathcal{A}_i$, допустимость относительно того же самого global set $\mathcal{A}$ сохраняется. Никакой mini-batch relaxation feasible set не вводится.

Одна итерация BCFW. Восстановить или инкрементально поддерживать $w(a^t)$; выбрать блоки B_t ; для каждого выбранного блока решить локальный LMO; обновить только эти a_i и соответствующий вклад в $q(a)$. Step size можно задать правилом или line search.

Рандомизированный single-block BCFW для Structural SVM имеет доказанные гарантии сходимости, вычисляемый duality gap и дешевую итерацию [4]. Важная практическая переменная --- не только $|B_t|$, но и sampling law: uniform, importance sampling по curvature/cost или gap-based sampling.

5.1. Почему это не stochastic gradient

В SGD случайный объект дает случайную оценку градиента primal objective, например $\nabla f_i(w)$, и обновление обычно покидает convex hull ранее найденных atoms. В BCFW используется точный block-gradient $\nabla_i F(a)$, определенный текущей глобальной агрегированной моделью $w(a)$. Случайность выбирает, *какой LMO спросить*, а не заменяет градиент шумной оценкой. Обновление остается условно-градиентным convex-combination step в feasible block. Поэтому корректное название --- randomized block oracle, а не stochastic gradient.

Это различие может размываться в реализации: если $w(a)$ или gradient tracker сами оценены стохастически, возникает гибрид stochastic BCFW. Но чистый BCFW такой аппроксимации не требует.

6. Децентрализованный переход

Пусть имеются N агентов, агент r владеет индексами I_r , а $\{I_r\}$ образуют partition датасета. Глобальная dual-переменная по-прежнему имеет product-структуру, но распределена физически:

$$\mathcal{A} = \prod_{r=1}^N \prod_{i \in I_r} \mathcal{A}_i, \quad q(a) = \sum_{r=1}^N q_r(a), \quad q_r(a) = \frac{1}{n} \sum_{i \in I_r} M_i^* a_i.$$

Проблема состоит не в локальном LMO --- он уже локален, --- а в том, что его gradient использует общий $w(a) = \nabla R^*(\sum_r q_r)$. Децентрализованный метод заменяет центральное агрегирование обмена по графу. У каждого агента могут храниться:

- локальные dual blocks $a_i, i \in I_r$;
- локальная копия модели или агрегата w_r^t/q_r^t ;
- при необходимости gradient-tracking state y_r^t .

Пусть W_t --- mixing matrix, согласованная с communication graph. Абстрактная DBCFW-итерация имеет вид:

$$\begin{aligned} \bar{z}_r^t &= \sum_{p=1}^N [W_t]_{rp} z_p^t && \text{(mixing/consensus),} \\ \hat{w}_r^t &= \mathcal{R}(\bar{z}_r^t, y_r^t) && \text{(локальная оценка общей модели),} \\ s_i^t &\in \arg \min_{u_i \in \mathcal{A}_i} \langle u_i, M_i \hat{w}_r^t - b_i \rangle, \quad i \in B_r^t && \text{(sampled local LMO),} \\ a_i^{t+1} &= (1 - \gamma_t) a_i^t + \gamma_t s_i^t, \quad \text{quadi} \in B_r^t && \text{(block FW update).} \end{aligned}$$

Конкретные рекурсии зависят от того, выполняется ли consensus по primal copies, по dual aggregate, по gradients или используется tracking. Decentralized FW можно анализировать как inexact FW: consensus error возмущает gradient/LMO, а connectivity и stepsize должны сделать эту ошибку суммируемой или достаточно быстро убывающей [8]. Для DBCFW добавляется sampling error/задержка обновления блоков. Корректная теорема требует явно зафиксировать network assumptions (double stochasticity или push-sum), bounded delay, частоту выбора каждого блока и точность LMO.

7. Классы задач

Таблица 1: Где возникает product-domain и что является блоковым oracle.

Класс	Dual block $\mathcal{A}_i$	Локальный ЛМО / оговорка
Structural SVM	simplex over structured outputs примера i	loss-augmented inference; часто динамическое программирование, matching или decoding [4, 7]
Multiclass hinge	simplex over incorrect labels	поиск максимального loss-augmented score
Binary hinge SVM	interval/simplex-type block	выбор активной margin alternative; классическая dual coordinate структура
Fenchel ERM	$\text{dom } f_i^*$	стандартный FW только если область компактна и нелинейная часть обработана; logistic conjugate содержит entropy, squared loss дает некомпактный dual domain [6]
Epigraph/threshold constraints	multipliers локальных inequalities	локальная линейная оптимизация, если нормировка multipliers дает compact polytope
Semi-relaxed transport	simplex column для одного demand/target	минимум стоимости по source alternatives; product возникает непосредственно из column marginals, иногда уже в primal constrained form
Network equilibrium	commodity/demand polytope	shortest path или local routing oracle; общие edge capacities могут связать блоки и требуют dualization/decomposition
Convex head поверх features	dual block примера при фиксированном feature extractor	корректное convex subproblem; end-to-end сеть в общем случае не покрывается

8. Граница обобщения на deep learning

Фраза «для произвольной DL-постановки» математически слишком сильна. Если score $g_w(x)$ нелинеен по trainable weights w , то даже convex loss как функция score обычно дает nonconvex composition как функцию w . Тогда:

1. перестановка $\min_w \max_a$ может иметь duality gap;
2. R^* больше не устраняет всю модель, потому что loss зависит от нелинейного g_w , а не от линейного $K_i w$;
3. dual optimum не обязан восстанавливать global primal optimum;
4. классический convex FW gap перестает быть сертификатом suboptimality.

Корректны четыре более узких пути.

1. **Fixed representation + convex head.** Заморозить backbone и dualize обучение линейной/structured головы.
2. **Convex subproblem внутри alternating method.** Использовать BCFW для routing, matching, attention/assignment или output-layer subproblem, не называя это dual всего DL objective.
3. **Convexification.** Перейти к kernel/NTK, infinite-width или measure formulation, если для нее действительно доказана convex equivalence.
4. **Nonconvex constrained FW.** Применять FW непосредственно к компактному constrained parameter set и доказывать convergence to stationarity. Это валидный FW, но product dual mechanism уже дру-

гой; decentralized nonconvex FW существует, однако дает stationarity, не global optimality [8].

Итак, переносимая идея для DL --- *искать convex, locally indexed subproblem или saddle layer*, а не автоматически dualize произвольную сеть.

9. Когда гипотеза не работает

Product-структура отсутствует или недостаточна для BCFW в следующих случаях:

- loss содержит пары/батчи с глобальной нормировкой, ranking constraints между примерами или dataset-level fairness constraint;
- dual domains некомпактны, поэтому FW LMO может не иметь решения;
- R не сильно выпукла и R^* негладка; standard smooth FW rate неприменим;
- локальный LMO сам NP-hard и не имеет контролируемой approximation guarantee;
- поддержание общего $w(a)$ дороже, чем полный проход по блокам;
- в decentralized сети communication/consensus error доминирует выигрыш от дешевого oracle;
- mini-batch настолько мал, что число rounds и synchronization latency перекрывают экономию local work.

10. Честное сравнение методов

Нельзя сравнивать full и block methods только по iteration count: одна full iteration вызывает все block oracles, одна BCFW iteration --- один или несколько. Нельзя также смешивать централизованную и децентрализованную пары.

Таблица 2: Минимальный протокол сравнения.

Срез	Что фиксировать и показывать
Centralized	FW vs BCFW: один objective, initialization, LMO implementation, stopping rule и tuning budget
Decentralized	DFW vs DBCFW: тот же graph sequence, agents, partition, mixing/tracking rule, precision и hardware
Oracle work	число block LMO calls; отдельно exact/approximate calls и их фактическое время
Pass-equivalent	$\sum_t B_t /n$ в central; в distributed --- нормировка по всем локальным блокам
Wall clock	end-to-end time, включая model recovery, sampling, line search, diagnostics и communication
Round time	критический путь раунда, а не сумма времени параллельных агентов
Communication	rounds, messages, bytes, topology changes; отдельно model и tracker payload
Quality	primal objective, dual objective, full/estimated gap, feasibility/consensus error, downstream metric
Statistics	одинаковые seeds/splits, confidence intervals, tuning policy и predeclared budget cuts

Полезно строить как минимум четыре графика: gap vs block-oracle calls, gap vs wall time, gap vs communication rounds и gap vs bytes. Победа по oracle work не является автоматически победой по времени или коммуникации. В decentralized setting особенно важно показывать две ошибки отдельно: optimization gap относительно consensus objective и network disagreement $N^{-1} \sum_r \|w_r - \bar{w}\|^2$.

11. Исследовательская программа и проверяемые гипотезы

H1: product discovery. Для каждой новой задачи выписать f_i^* или max-form, доказать strong duality и явно проверить, нет ли coupled constraints.

H2: oracle economy. Измерить распределение стоимости C_i . BCFW должен выигрывать прежде всего при высокой стоимости full sweep и возможности дешево инкрементировать $q(a)$ и $w(a)$.

H3: sampling. Сравнить uniform, importance-by-cost, gap sampling и mini-batch selection при одинаковом oracle/time budget.

H4: network trade-off. Для DFW/DBCFW варьировать spectral gap графа, data heterogeneity и число local steps per communication. Ожидается область, где block work экономит время, и область, где дополнительные rounds доминируют.

H5: DL boundary. Сравнить frozen-backbone convex head, alternating convex layer и end-to-end nonconvex baseline. Claims о dual certificates делать только для первых двух режимов.

12. Вывод

Дуализация обнаруживает скрытую блочную структуру, когда три свойства совпадают: (i) primal loss/constraints являются суммой локальных выпуклых компонент; (ii) coupling проходит через общий линейный параметр и регуляризатор; (iii) локальные conjugate/max domains компактны и доступны через дешевый LMO. Сильная выпуклость R превращает coupling в гладкий dual objective, а product feasibility делает LMO block-separable. В max-form случае FW gap одновременно является primal--dual certificate.

Поэтому BCFW не является эвристическим урезанием полного FW: он оптимизирует ту же dual задачу на том же feasible set, но распределяет вызовы дорогого oracle во времени. DBCFW добавляет физическое распределение блоков и приближенное восстановление общей модели через consensus/tracking. Практическая полезность определяется не числом итераций, а совместным бюджетом oracle work, wall time и communication.

Самая сильная корректная формулировка общей идеи такова:

Если регуляризованный convex ERM или constrained problem допускает локально-сепарабельную saddle/Fenchel форму, а общий параметр можно устранить через гладкое сопряжение регуляризатора, то dual feasible set часто является произведением локальных областей. Тогда block-coordinate и decentralized block-coordinate Frank--Wolfe являются естественными алгоритмами, особенно когда локальный LMO дорог, но существенно дешевле полного sweep.

Список литературы

- [1] Amir Beck, Edouard Pauwels, and Shoham Sabach. The cyclic block conditional gradient method for convex optimization problems. *SIAM Journal on Optimization*, 25(4):2024--2049, 2015. doi: 10.1137/140978357.
- [2] Stephen Boyd and Lieven Vandenbergh. *Convex Optimization*. Cambridge University Press, 2004. URL <https://web.stanford.edu/~boyd/cvxbook/>.
- [3] Martin Jaggi. Revisiting frank--wolfe: Projection-free sparse convex optimization. In *Proceedings of the 30th International Conference on Machine Learning*, volume 28 of *Proceedings of Machine Learning Research*, pages 427--435, 2013. URL <https://proceedings.mlr.press/v28/jaggi13.html>.

- [4] Simon Lacoste-Julien, Martin Jaggi, Mark Schmidt, and Patrick Pletscher. Block-coordinate frank-wolfe optimization for structural SVMs. In *Proceedings of the 30th International Conference on Machine Learning*, volume 28 of *Proceedings of Machine Learning Research*, pages 53--61, 2013. URL <https://proceedings.mlr.press/v28/lacoste-julien13.html>.
- [5] R. Tyrrell Rockafellar. *Convex Analysis*. Princeton University Press, 1970. doi: 10.1515/9781400873173.
- [6] Shai Shalev-Shwartz and Tong Zhang. Stochastic dual coordinate ascent methods for regularized loss minimization. *Journal of Machine Learning Research*, 14:567--599, 2013. URL <https://www.jmlr.org/papers/v14/shalev-shwartz13a.html>.
- [7] Ioannis Tsochantaridis, Thorsten Joachims, Thomas Hofmann, and Yasemin Altun. Large margin methods for structured and interdependent output variables. *Journal of Machine Learning Research*, 6:1453--1484, 2005. URL <https://www.jmlr.org/papers/v6/tsochantaridis05a.html>.
- [8] Hoi-To Wai, Jean Lafond, Anna Scaglione, and Eric Moulines. Decentralized frank--wolfe algorithm for convex and nonconvex problems. *IEEE Transactions on Automatic Control*, 62(11):5522--5537, 2017. doi: 10.1109/TAC.2017.2685559.