

Decentralized Block-Coordinate Frank-Wolfe для semi-relaxed OT color transfer

Экспериментальный сетайп репозитория `dbcfw_timevarying_benchmark`

22 июня 2026

Аннотация

В документе описан новый экспериментальный сетайп для задачи переноса цветовой палитры через semi-relaxed optimal transport. Мы берем постановку semi-relaxed OT, в которой одна маргиналь сохраняется точно, а другая штрафуетя квадратично, и поднимаем ее в децентрализованный режим. Сравниваются два децентрализованных projection-free метода: DFW как полный Frank-Wolfe шаг по всем столбцам транспортного плана и DBCFW как блочный Frank-Wolfe шаг по одному столбцу. Основной результат: при одинаковом oracle budget DBCFW достигает меньшего objective residual, меньшего Frank-Wolfe duality gap и более точной транспортной матрицы относительно сильного централизованного BCFW reference. Это честное сравнение по числу вызовов линейного оракула, но не по числу коммуникационных раундов.

1. Контекст и литература

Классический optimal transport (OT) сравнивает распределения через стоимость переноса массы. В дискретной форме эта задача восходит к линейной программе Канторовича и является стандартным инструментом для вычислительной математики, imaging и machine learning; см. обзор Peyré and Cuturi [6]. Для color transfer OT естественен: цвета изображения представляются как распределение в RGB-пространстве, а транспортный план задает, как цвета исходного изображения переводятся в цвета целевого. Relaxed и regularized OT для цветовых преобразований обсуждаются, например, у Ferradans et al. [1].

Frank-Wolfe, или conditional gradient, был предложен Frank and Wolfe [2] как projection-free метод для гладкой выпуклой оптимизации на компактных выпуклых множествах. Современная интерпретация через linear minimization oracle (LMO) и duality gap дана в Jaggi [4]. Для задач с блочно-разделимыми ограничениями естественен BCFW: обновляется не весь объект, а один блок или батч блоков. Такая идея систематически изучалась, в частности, у Lacoste-Julien et al. [5]. Для децентрализованного режима используется линия работ о decentralized FW и consensus/tracking механизмах, например Wai et al. [7].

Ближайшая к нашему OT-сетайпу работа - статья Fukunaga and Kasai [3]. Авторы рассматривают fast BCFW для semi-relaxed OT, показывают связь linearization duality gap с лагранжевым gap и демонстрируют эффективность на color transfer. В нашем эксперименте центральная идея той статьи переносится в децентрализованный запуск: мы сравниваем не только FW против BCFW, а DFW против DBCFW в одном и том же distributed graph setup.

2. Математическая постановка

Пусть исходное изображение аппроксимировано палитрой

$$\mu_s = \sum_{i=1}^m a_i \delta_{x_i}, \quad a \in \Delta_m, \quad x_i \in \mathbb{R}^3,$$

а целевое изображение - палитрой

$$\mu_t = \sum_{j=1}^n b_j \delta_{y_j}, \quad b \in \Delta_n, \quad y_j \in \mathbb{R}^3.$$

В эксперименте $m = n = 32$, а центры x_i, y_j получаются k-means кластеризацией пикселей в RGB-пространстве. Стоимость переноса задается матрицей

$$C_{ij} = \|x_i - y_j\|_2^2.$$

Balanced OT решает линейную программу

$$\min_{T \geq 0} \langle C, T \rangle \quad \text{s.t.} \quad T \mathbf{1}_n = a, \quad T^\top \mathbf{1}_m = b,$$

где T_{ij} - масса, отправленная из исходного цвета x_i в целевой цвет y_j . Для изображений жесткое сохранение обеих маргиналей может быть слишком ограничительным: палитры могут иметь разные массы и разную выраженность цветовых мод. Поэтому используется semi-relaxed OT:

$$\min_{T \in \mathcal{D}_b} f(T) = \langle C, T \rangle + \frac{1}{2\lambda} \|T \mathbf{1}_n - a\|_2^2, \quad \mathcal{D}_b = \{T \in \mathbb{R}_+^{m \times n} : T^\top \mathbf{1}_m = b\}. \quad (1)$$

Параметр $\lambda > 0$ управляет силой штрафа за нарушение исходной маргинали. Чем меньше λ , тем ближе задача к balanced OT по строкам; чем больше λ , тем свободнее источник может менять массы.

Градиент цели имеет простой вид:

$$\nabla f(T) = C + \frac{1}{\lambda} (T \mathbf{1}_n - a) \mathbf{1}_n^\top. \quad (2)$$

Ограничение $\mathcal{D}_b$ разделяется по столбцам: каждый столбец $T_{:j}$ лежит в scaled simplex

$$\{u \in \mathbb{R}_+^m : \mathbf{1}_m^\top u = b_j\}.$$

Поэтому LMO для FW раскладывается на независимые столбцовые задачи. Для заданного градиента G :

$$S(G)_{:j} = b_j e_{i_j}, \quad i_j \in \arg \min_{i \in \{1, \dots, m\}} G_{ij}. \quad (3)$$

Именно эта структура делает BCFW особенно подходящим для semi-relaxed OT: один блочный шаг обновляет один или несколько столбцов транспортного плана, не решая большую проекционную задачу.

Для контроля сходимости используется стандартный Frank-Wolfe gap:

$$g(T) = \langle T - S(\nabla f(T)), \nabla f(T) \rangle. \quad (4)$$

Для выпуклой гладкой задачи это не просто эвристика: $g(T)$ является вычислимым сертификатом субоптимальности, то есть $f(T) - f(T^*) \leq g(T)$ при точном LMO.

3. Как транспортный план дает color transfer

После оптимизации план T переводится в стохастическую строковую матрицу

$$P_{ij} = \frac{T_{ij}}{\sum_{\ell=1}^n T_{i\ell}} \quad \text{если} \quad \sum_{\ell} T_{i\ell} > 0.$$

Затем каждый исходный цвет x_i заменяется барицентрическим целевым цветом

$$\hat{x}_i = \sum_{j=1}^n P_{ij} y_j.$$

Пиксель исходного изображения сначала получает label ближайшего palette center x_i , после чего перекрашивается в $\hat{x}_i$. Поэтому ошибка транспортной матрицы относительно reference важнее, чем только визуальное впечатление: если T близок к reference, то и row-normalized mapping ближе к желаемому OT color map.

4. Сравнимые методы

FW. Centralized FW на каждой итерации считает полный градиент, решает LMO по всем n столбцам и делает шаг

$$T_{k+1} = (1 - \gamma_k)T_k + \gamma_k S(\nabla f(T_k)).$$

В нашем децентрализованном сравнении прямым аналогом является DFW: каждый агент делает полный FW-шаг по всем столбцам, а затем состояние и gradient tracker смешиваются по графу.

BCFW. BCFW выбирает блок $B_k \subset \{1, \dots, n\}$ и решает LMO только по этим столбцам:

$$D_{:j} = S(\nabla f(T_k))_{:j} - T_{k,:j}, \quad j \in B_k, \quad D_{:j} = 0, \quad j \notin B_k.$$

После этого выполняется line search по направлению D . При $B_k = \{1, \dots, n\}$ получаем обычный FW. При $|B_k| = 1$ получаем максимально блочный режим, который особенно дешев по LMO, но требует больше итераций.

DFW. В децентрализованном режиме есть N агентов. Агент p хранит свой план $T_k^{(p)}$ и локальный gradient tracker. На каждом раунде применяется doubly stochastic mixing matrix W_k , соответствующая текущему коммуникационному графу:

$$\bar{T}_k^{(p)} = \sum_{q=1}^N W_{k,pq} T_k^{(q)}.$$

После смешивания агент строит FW-направление по всем столбцам. В нашем коде DFW реализуется как тот же decentralized routine, но с batch size n .

DBCFW. DBCFW использует тот же граф, тот же tracker и тот же line-search механизм, но обновляет малый набор столбцов. В reported run используется batch size 1:

$$|B_k^{(p)}| = 1.$$

То есть каждый агент за один раунд решает только один столбцовый LMO, а весь прогресс на уровне полного плана набирается частыми локальными шагами. Это и есть наш децентрализованный блочно-координатный перенос идеи BCFW на semi-relaxed OT.

5. Экспериментальный дизайн

Основной color-transfer запуск:

Параметр	Значение
Source / target	rocket $\rightarrow$ coffee
Число цветов	$m = n = 32$
Агенты	$N = 8$
Relaxation	$\lambda = 0.08$
Graph	Erdos-Renyi connected, edge probability 0.45
Seed / graph seed	202 / 1202
Cost noise	0.0
Stepsize	exact line search along FW direction
Reference	centralized BCFW, 1000 oracle epochs
Budget for DFW/DBCFW	80 oracle epochs

Reference нужен не как competing method, а как сильная аппроксимация T^* для метрик. Он строится централизованным BCFW с существенно большим бюджетом: 1000 oracle epochs. Для DFW и DBCFW бюджет одинаков по числу LMO-column calls:

$$\text{oracle epochs} = \frac{\text{total LMO columns}}{Nn}.$$

Это честная единица вычислительной работы, потому что и DFW, и DBCFW используют один и тот же столбцовый LMO (3); отличается только группировка этих вызовов по итерациям.

Важно: сравнение не является честным по коммуникациям. DFW делает 80 communication rounds, а DBCFW - 2560 rounds, потому что один полный DFW round обрабатывает $n = 32$ столбца, а DBCFW обрабатывает один столбец за round. Поэтому основной вывод формулируется как oracle-efficiency win, а не communication-efficiency win.

6. Метрики

Мы используем четыре основные метрики:

1. Objective residual к сильному reference:

$$f(T_k) - f(T_{\text{ref}}).$$

Это показывает, насколько хорошо метод минимизирует именно semi-relaxed OT objective.

2. Frank-Wolfe duality gap $g(T_k)$ из (4). Это внутренний сертификат качества FW-типа методов.

3. Ошибка транспортного плана:

$$e_M(T_k) = \frac{\|T_k - T_{\text{ref}}\|_F}{\|T_{\text{ref}}\|_F}.$$

Эта метрика важна для color transfer, потому что именно транспортный план задает mapping цветов.

4. Variance of column gaps. Для столбца j берется локальный вклад в FW gap:

$$g_j(T) = \langle T_{:,j} - S(\nabla f(T))_{:,j}, \nabla f(T)_{:,j} \rangle,$$

и далее считается дисперсия по j . Низкая дисперсия означает, что метод не оставляет отдельные столбцы сильно недообработанными.

7. Результаты

Таблица 1: Финальные значения после 80 oracle epochs. Меньше - лучше для всех метрик, кроме budget columns.

Метрика	DFW	DBCFW	Улучшение DBCFW
$f(T) - f(T_{\text{ref}})$	$7.230 \cdot 10^{-3}$	$9.118 \cdot 10^{-4}$	$7.9 \times$ ниже
FW duality gap	$1.282 \cdot 10^{-2}$	$1.077 \cdot 10^{-3}$	$11.9 \times$ ниже
Transport matrix error	$2.027 \cdot 10^{-1}$	$5.498 \cdot 10^{-2}$	$3.7 \times$ ниже
Column-gap variance	$1.147 \cdot 10^{-7}$	$1.325 \cdot 10^{-9}$	$86.5 \times$ ниже
Communication rounds	80	2560	не win по коммуникациям

Reference objective равен

$$f(T_{\text{ref}}) = 0.054690, \quad g(T_{\text{ref}}) = 1.17 \cdot 10^{-4}.$$

После равного oracle budget DBCFW приходит к objective 0.055602, тогда как DFW останавливается на 0.061919. Разница не сводится к одному gap: DBCFW также заметно ближе к самой reference transport matrix.

Semi-relaxed OT color transfer: как падают лоссы

$$\min_{T \geq 0, T^T \mathbf{1} = b} f(T) = \langle C, T \rangle + \frac{1}{2\lambda} \|T\mathbf{1} - a\|_2^2, \quad \lambda = 0.08, m = n = 32, N = 8$$

Равный oracle budget: $X = \text{total LMO-column calls} / (N \cdot n)$. Коммуникации не равны: DFW 80, DBCFW 2560 rounds.




Рис. 1: Основной результат. При одинаковом числе LMO-column calls DBCFW быстрее снижает objective residual, FW duality gap, ошибку транспортного плана и variance of column gaps. Ось x - oracle epochs, а не communication rounds.




Рис. 2: Визуальная проверка color transfer. DBCFW ближе к semi-relaxed reference не только по objective/gap, но и по виду итогового переноса цветов.

8. Почему DBCFW выигрывает в этом сетапе

Главная причина - структура области $\mathcal{D}_b$. Ограничения по столбцам независимы, а LMO (3) решается отдельно для каждого target color. В DFW полный шаг одновременно меняет все столбцы и использует один общий step size. Такой шаг может быть консервативным: хорошие направления для разных столбцов имеют разную локальную геометрию, но им приходится двигаться с общей γ_k .

DBCFW обновляет один столбец за раз. При равном числе LMO-column calls это означает большее число мелких descent/mixing steps. Каждый блочный шаг получает собственный line search, а column gaps быстрее выравниваются. Это видно по метрике column-gap variance: она у DBCFW ниже примерно в $86.5\times$. С практической точки зрения это означает, что метод не просто уменьшает глобальный gap, а равномернее дорабатывает transport plan по целевым цветам.

Второй фактор - близость задачи к блочной модели из Fukunaga and Kasai [3]. Их центральный результат состоит в том, что BCFW особенно полезен для semi-relaxed OT. Наш результат согласуется с этой картиной: когда semi-relaxed OT переносится в децентрализованный setup, блочная версия сохраняет преимущество по oracle-efficiency.

9. Почему сравнение справедливое и где его границы

Сравнение справедливое в следующем смысле:

- одна и та же задача: те же изображения, палитры, cost matrix, λ , seed;
- один и тот же network setup: $N = 8$, тот же Erdos-Renyi graph seed;
- одинаковая инициализация транспортного плана;
- одинаковый столбцовый LMO;
- одинаковый line search;
- одинаковый oracle budget: 80 oracle epochs.

Сравнение не справедливое по communication rounds, и это сознательно отражено в подписи к Figure 1. Если в приложении главным ресурсом является связь, нужно дополнительно сравнивать кривые против communication rounds или wall-clock time. В текущем документе утверждение такое: DBCFW лучше по oracle budget для semi-relaxed OT color transfer. Это не утверждение о меньшей коммуникационной цене.

10. Как воспроизвести

Запуск, соответствующий сохраненным результатам:

```
cd experiments/dbcfw_timevarying_benchmark
python -m dbcfw_bench.cli ot-color-transfer \
  --source rocket \
  --target coffee \
  --colors 32 \
  --agents 8 \
  --epochs 80 \
  --batch 1 \
  --relaxation 0.08 \
  --cost-noise 0.0 \
  --stepsize line_search \
  --graph erdos \
  --edge-prob 0.45 \
```

```
--seed 202 \  
--graph-seed 1202 \  
--reference-epochs 1000 \  
--out runs_ot_color/figure9_rocket_to_coffee
```

Сырые метрики лежат в:

```
experiments/dbcfw_timevarying_benchmark/  
runs_ot_color/figure9_rocket_to_coffee/
```

Основные файлы:

- color_transfer_results.csv;
- semi_relaxed_reference_results.csv;
- color_transfer_plans.npz.

11. Вывод

В semi-relaxed OT color-transfer задаче DBCFW оказался существенно сильнее DFW при равном oracle budget. Это подтверждается сразу несколькими метриками: objective residual ниже в $7.9\times$, FW duality gap ниже в $11.9\times$, ошибка транспортной матрицы ниже в $3.7\times$. Поэтому утверждение ``наш подход лучше'' корректно формулировать так: децентрализованный block-coordinate FW лучше полного decentralized FW для этой задачи, когда главным ресурсом считается число вызовов столбцового LMO. При этом за выигрыш платим большим числом communication rounds, что нужно честно указывать в статье.

Список литературы

- [1] Sira Ferradans, Nicolas Papadakis, Gabriel Peyré, and Jean-François Aujol. Regularized discrete optimal transport. *SIAM Journal on Imaging Sciences*, 7(3):1853--1882, 2014. doi: 10.1137/130929886. URL <https://arxiv.org/abs/1307.5551>.
- [2] Marguerite Frank and Philip Wolfe. An algorithm for quadratic programming. *Naval Research Logistics Quarterly*, 3(1--2):95--110, 1956. doi: 10.1002/nav.3800030109.
- [3] Takumi Fukunaga and Hiroyuki Kasai. Fast block-coordinate Frank-Wolfe algorithm for semi-relaxed optimal transport, 2021. URL <https://arxiv.org/abs/2103.05857>.
- [4] Martin Jaggi. Revisiting Frank-Wolfe: Projection-free sparse convex optimization. In *Proceedings of the 30th International Conference on Machine Learning*, volume 28 of *Proceedings of Machine Learning Research*, pages 427--435. PMLR, 2013. URL <https://proceedings.mlr.press/v28/jaggi13.html>.
- [5] Simon Lacoste-Julien, Martin Jaggi, Mark Schmidt, and Patrick Pletscher. Block-coordinate Frank-Wolfe optimization for structural SVMs. In *Proceedings of the 30th International Conference on Machine Learning*, volume 28 of *Proceedings of Machine Learning Research*, pages 53--61. PMLR, 2013. URL <https://proceedings.mlr.press/v28/lacoste-julien13.html>.
- [6] Gabriel Peyré and Marco Cuturi. Computational optimal transport. *Foundations and Trends in Machine Learning*, 11(5--6):355--607, 2019. doi: 10.1561/22000000073. URL <https://arxiv.org/abs/1803.00567>.
- [7] Hoi-To Wai, Jean Lafond, Anna Scaglione, and Eric Moulines. Decentralized Frank-Wolfe algorithm for convex and nonconvex problems. *IEEE Transactions on Automatic Control*, 62(11):5522--5537, 2017. doi: 10.1109/TAC.2017.2678819. URL <https://arxiv.org/abs/1612.01216>.




Рис. 3: Транспортные матрицы и row-normalized transport matrices. Для переноса цвета используется именно row-normalized версия плана.